

Oyun Ekran Görüntülerinden Oyun Tespiti

MLP, Sıfırdan CNN ve Transfer Learning Mimarilerinin Karşılaştırmalı Analizi

Mehmet Ali Topkara — 23291093

Ankara Üniversitesi · Yapay Zeka ve Veri Mühendisliği

2025–2026 Bahar Dönemi

Proje Özeti

10 sınıflı oyun ekran görüntüsü sınıflandırması · 5 model: 2 baseline (MLP, CNN scratch) + 3 transfer learning (ResNet50, EfficientNetB0, ViT-Base/16) · FastAPI + React
lokal web demosu · belirsizlik göstergesi

Neden Bu Konu?

Gaming sektörü, manuel etiketlemenin sınırları ve sınıf çeşitliliği

Oyun sektörünün küresel hacmi 2024 itibarıyla yaklaşık **200 milyar dolara** ulaşmıştır. Twitch ve YouTube Gaming gibi platformlara her gün milyonlarca saatlik gameplay görüntüsü yüklenmekte, bu içeriğin manuel olarak kategorize edilmesi pratikte mümkün olmamaktadır.

Otomatik sınıflandırma sistemleri bu noktada arama, içerik moderasyonu, telif kontrolü ve öneri sistemleri için kritik bir altyapı haline gelmiştir. Görsel olarak da zorlu bir problemdir: özellikle FPS oyunları benzer arayüzlere sahiptir, MMORPG'ler aynı sahnede çok farklı görseller üretir, ve aynı oyun farklı modlarında oldukça farklı görünebilir.

Konu Seçiminde Çeşitlilik

Sınıf arkadaşlarımdan büyük çoğunluğu **sağlık ve insan tabanlı** görüntü sınıflandırma problemlerini (tıbbi görüntüler, yüz tanıma, duygu analizi vb.) tercih etmiştir. Ben **çeşitlilik** açısından farklı bir bağlam seçerek **oyun ekran görüntülerini** seçtim — hem sektörel olarak güncel, hem de görsel zorluk açısından zengin bir problem alanı sunduğu için.

Problem, Araştırma Sorusu ve Birincil Metrik

Closed-set sınıflandırma · hipotez · neden Macro-F1?

Problem Tanımı

Tek bir oyun ekran görüntüsü verildiğinde, modelin görseli **10 önceden tanımlı sınıftan birine** atfetmesi (closed-set sınıflandırma).

Araştırma Sorusu

Görüntü yapısını yok sayan **MLP**, sıfırdan eğitilen **klasik CNN** ve ImageNet üzerinde eğitilmiş **transfer learning** modelleri aynı veri setinde nasıl performans gösterir? Mimari değişiminin ve pretrained ağırlıkların etkisi sayısal olarak ne kadardır?

Hipotez

MLP düşük performans verir; CNN scratch belirgin sıçrama yapar; transfer learning marjinal ek iyileştirme sağlar — fakat **maliyet açısından** transfer modeller çok daha pahalıdır.

Birincil Metrik: Macro-F1

Veri dengeli (sınıf başına 1000 örnek) olduğundan accuracy ve weighted-F1 yakın çıkmaktadır. Ancak **Macro-F1** her sınıfa **eşit ağırlık** verir; precision ve recall'u harmonik ortalama ile birleştirir — bu da adil mimari karşılaştırması için akademik standarttır. Tüm yorumlar bu metrik üzerinden yapılır.


Veri Seti — Kaynak ve Yapısı

Kaggle Gameplay Images · 10 sınıf × 1000 örnek

Çalışmada **Kaggle** platformunda yayınlanan **Gameplay Images** veri seti kullanılmıştır. Veri seti 10 farklı popüler oyundan **toplam 10.000 ekran görüntüsü** içermektedir; her sınıf için **1000 örnek** bulunmakta ve sınıf dağılımı **mükemmel şekilde dengelidir** (sağdaki grafik).

Görseller **640×360 piksel** çözünürlükte PNG formatında sunulmuştur. Eğitim öncesinde tümü 224×224'e yeniden boyutlandırılarak ImageNet üzerinde önceden eğitilmiş modellerin beklediği girdi boyutuyla uyumlu hale getirilmiştir.

Sınıflar: **Among Us, Apex Legends, Fortnite, Forza Horizon, Free Fire, Genshin Impact, God of War, Minecraft, Roblox, Terraria**.



Bu çalışmada veri seti hiçbir sentetik artırma yapılmadan, kaynağında olduğu gibi 10×1000 dağılımıyla kullanılmıştır.

Veri Ön İşleme ve Bölme

RGBA → RGB · stratified split · augmentation

Veri seti üzerindeki ilk işlem, modellerin işleyebileceği tek tip **RGB formatına dönüştürülmesi** olmuştur. Ham görsellerin yaklaşık %20'si RGBA (alfa kanallı) formatta olduğundan, eğitim öncesinde RGB'ye çevrilmiştir. Tüm görseller **224×224 piksele** yeniden boyutlandırılarak ImageNet pretrained modelleriyle uyumlu hale getirilmiştir.


Eğitim verisi üzerinde genelleme kabiliyetini artırmak amacıyla **augmentation** uygulanmıştır: rastgele kırpma (RandomCrop 224), yatay çevirme, renk titreşimi (ColorJitter — parlaklık, kontrast, doygunluk) ve $\pm 10^\circ$ rotation. Validation ve test setlerinde sadece deterministik resize + center crop kullanılmıştır. ImageNet ortalama-standart sapma değerleriyle normalizasyon yapılmıştır.

Veri Bölme — Stratified 70/15/15

Veri seti **stratified split** ile bölünmüştür: **%70 eğitim (7000 görsel), %15 doğrulama (1500 görsel), %15 test (1500 görsel)**. Stratified yöntemi her sınıftan eşit oranda örnek alarak train/val/test dağılımını korur — bizim setimiz dengeli olduğu için sonuç eşit oran ile aynı, ancak yöntem **reproducibility** ve doğru pratiği sağlar. Bölme **seed=42** ile sabitlenmiş, eğitim ile test seti hiçbir noktada karışmamıştır.

MLP — Yapay Sinir Ağı Baseline

Tam bağlı katmanlar · görüntü yapısını yok sayar




MLP baseline'ımız görüntüyü düz bir vektöre çevirerek **üç tam bağlı katmandan** geçirir. Girdi katmanı $224 \times 224 \times 3 = 150.528$ piksel değeri kabul eder; oradan **256 nöronluk** ilk gizli katmana, sonra **128 nöronluk** ikinci gizli katmana, son olarak **10 sınıflık** çıktı katmanına bağlanır.

Her gizli katmandan sonra **ReLU aktivasyonu** ve **Dropout 0.3** uygulanır. Toplam **38,57 milyon** parametre içerir; bunlar tamamen tam bağlı katmanlardadır ve **pretrained değildir**.

Eğitim: AdamW optimizier ($lr=1e-3$), CosineAnnealingLR scheduler, batch size 64, **20 epoch** maksimum, **early stopping patience=5**. Eğitim **11,8 dakika** sürmüş ve 19. epoch'ta **best val_acc 0,5053** elde edilmiştir.

CNN Scratch — Sıfırdan Eğitilen Klasik CNN

VGG-mini tarzı · 4 evrişim bloğu · 0.42M parametre



Sıfırdan eğitilen CNN baseline'ımız **VGG-mini** tarzında **dört evrişim bloğundan** oluşur. Her blok bir 3×3 convolution, batch normalization, ReLU aktivasyonu ve 2×2 maxpooling içerir. Filter sayıları her blokta iki katına çıkar ($32 \rightarrow 64 \rightarrow 128 \rightarrow 256$), feature map çözünürlüğü ise yarıya düşer ($224 \rightarrow 112 \rightarrow 56 \rightarrow 28 \rightarrow 14$).

Son convolution bloğunun çıktısı **global average pooling** ile 256 boyutlu bir vektöre indirgenir; ardından 128 birimlik bir tam bağlı katman üzerinden 10 sınıflık tahmin üretilir. Toplam parametre sayısı yalnızca **0,42 milyondur** — yani MLP'den **92 kat daha az**, fakat görüntü yapısını sömürdüğü için sonuçları çok daha iyidir.

Eğitim: AdamW ($\text{lr}=1\text{e-}3$), AMP mixed precision, **20 epoch + patience=5**. Eğitim **11,1 dakika** sürmüştür, 19. epoch'ta **best val_acc 0,9680** elde edilmiştir — ImageNet pretrained kullanmadan, sıfırdan.

Transfer Learning + 3 Modern Mimari

ImageNet ön-eğitilmiş ağırlıklar · ResNet, EfficientNet, ViT

Transfer learning, ImageNet (1.2 milyon görsel, 1000 sınıf) üzerinde önceden eğitilmiş ağırlıkların kendi probleme uyarlanmasıdır. Tüm katmanlar fine-tune edilir; backbone dondurulmaz. Bu strateji, 10K görsellik küçük bir veri setiyle bile **yüksek doğruluk** sağlar.

ResNet50

2015 · Klasik CNN

23.5M parametre

Yapı taşı:

Residual Block

Skip bağlantılarıyla derin (50+ katman) CNN. 20 epoch + early stop, AMP, lr=1e-4. 10.6 dk'da %99.13 macro-F1.

EfficientNetB0

2019 · Modern CNN

4.0M parametre

Yapı taşı:

MBConv + Compound Scaling

Mobile inverted bottleneck + 3 boyutu birlikte ölçekler. 20 epoch + early stop, AMP, lr=1e-4. 9.5 dk'da %99.07 macro-F1.

ViT-Base/16

2020 · Transformer

85.8M parametre

Yapı taşı:

Patch Token + Self-Attention

Görseli 16×16 patch'lere böler, NLP transformer'ını uygular. 20 epoch + early stop, AMP, lr=1e-4, batch 16. 19.5 dk'da %99.07 macro-F1.

Üçü de ****timm**** kütüphanesi üzerinden ImageNet pretrained ağırlıklarla yüklendi — tutarlı API ve aynı eğitim transformları sağlar.

Eğitim Protokolü ve Alternatif Yaklaşımlar

Adil karşılaştırma için 5 modelde ortak strateji

Ortak Hiperparametreler

Tüm modeller **aynı protokolde** eğitildi — adil karşılaştırma için kritik. Optimizer **AdamW** (weight decay 1e-4), scheduler **CosineAnnealingLR** ile öğrenme oranı kosinüs eğrisinde 0'a iniyor. Loss fonksiyonu CrossEntropyLoss.

Maksimum **20 epoch**, **early stopping patience=5** — yani 5 ardışık epoch iyileşme olmazsa eğitim durur. Baseline modeller (MLP, CNN scratch) için lr=1e-3, transfer learning modelleri için daha küçük lr=1e-4 (pretrained ağırlıkları bozmamak için).

AMP — Automatic Mixed Precision (FP16 + FP32 karışımı) transfer ve CNN scratch eğitimlerinde aktif; yaklaşık **%40 hızlanma** sağladı, doğruluğa zarar vermedi.

Reproducibility: **seed=42**, deterministic dataloader. Crash recovery için her epoch sonu checkpoint (resume desteği).

Düşünüp Uygulamadığım Alternatifler

Yaklaşım	Neden seçmedim
Sıfırdan eğitim	10K yetmez, %20-30 düşüş bekleniyor
Frozen backbone	Hızlı ama doğruluk %3-5 düşer
LoRA / Adapter	LLM için anlamlı, 86M ViT için marjinal
Mixup / CutMix	%1-2 ek doğruluk ama odağı dağıtır
K-Fold CV (5)	5× hesaplama, tek tahmin için yeterli

Sonuçlar — 5 Model Test Performansı

1500 örnekli test seti · birincil metrik Macro-F1

Model	Acc	Macro-F1	Top-3	Params	Boyut	Inf (ms)	Eğitim
MLP	0.5027	0.4794	0.7600	38.57M	147.1 MB	9.83	11.8 dk
CNN Scratch	0.9733	0.9733	0.9967	0.42M	1.6 MB	9.13	11.1 dk
ResNet50	0.9913	0.9913	0.9973	23.53M	89.8 MB	9.29	10.6 dk
EfficientNetB0	0.9907	0.9907	0.9973	4.02M	15.3 MB	9.99	9.5 dk
ViT-Base/16	0.9907	0.9907	0.9953	85.81M	327.3 MB	12.01	19.5 dk

Anahtar Gözlemler

MLP ile transfer arası yaklaşık 0,51 macro-F1 farkı bulunmaktadır — görüntü yapısını sömüren mimarilerin değeri net biçimde görülür.



CNN Scratch yalnızca 0,42M parametre ile 0,9733 macro-F1'e ulaşmıştır; ResNet50'nin 0,9913 ile arasında **sadece 0,018 fark** var — yani transfer learning'in marjinal katkısı bu görevde **küçüktür**, esas sıçrama MLP→CNN geçişinde yaşanır.

Transfer learning grubunda fark istatistiksel gürültü içinde (0,06%); **EfficientNetB0** 21× daha az parametre ve 6× daha küçük dosyayla pratik olarak en akıllı tercih.

Eğitim Eğrileri Karşılaştırması

5 modelin train/val loss ve accuracy seyri


Eğitim Eğrileri — 5 Model Overlay



MLP düşük accuracy'de plato yapar (%50). CNN Scratch hızlı yakınsar ve %96+ seviyesine çıkar. Transfer learning modelleri ilk birkaç epoch'ta zaten %95 üzerine çıkar — ImageNet ağırlıklarının değeri burada görünür.

Sınıf-Bazlı F1 Analizi

5 model × 10 sınıf — hangi sınıflar zor?




Her sınıf için 5 modelin F1 skoru yan yana gösterilmektedir (gri=MLP · turuncu=CNN Scratch · mavi=ResNet50 · yeşil=EfficientNetB0 · kırmızı=ViT-Base/16).

MLP'nin Apex Legends ve Free Fire F1'i 0,2 civarında — model bu iki FPS'yi birbirine karıştırıyor. **CNN Scratch** ve transfer modelleri tüm sınıflarda 0,95 üstü; en zor sınıf yine **Apex Legends** (benzer HUD).

Hata Analizi — Confusion Matrices

5 model için normalize edilmiş confusion matrix grid



Diagonal = doğru tahmin (recall). **MLP**'nin matrisi dağınıktır; özellikle Apex Legends, Free Fire ve God of War satırlarında yanlış tahminler yoğun. **CNN Scratch ve transfer** modellerinin diagonal'leri belirgin şekilde temizlenir.

Tüm modellerde en zor karışan sınıf ikilisi **Apex Legends ↔ Free Fire** — her ikisi de battle royale FPS, benzer HUD elementleri (mini harita, sağlık barı, silah göstergesi) taşıdığı için karıştırılması beklenen bir durum.

Grad-CAM ve EigenCAM — Modelin Nereye Baktığı?

Heatmap görselleştirmesi · neden ViT için EigenCAM?

Bir modelin %99 doğruluk vermesi yetmez — **kararına hangi piksellerin etki ettiği** sorusu da önemlidir. Heatmap görselleştirmesi bu görünmez mantığı açığa çıkarır; model debug ve güven açısından kritiktir.

GradCAM (CNN'ler için)

Son convolution katmandaki **gradient** $\times$ **activation** çarpımı. Sınıf-özel: hangi piksel "Fortnite" kararına ne kadar katkı verdi.

CNN Scratch için son conv bloğu ($256 \times 14 \times 14$), **ResNet50** için layer4'ün son bloğu, **EfficientNetB0** için son MBConv stage'i kullanılır.

EigenCAM (ViT için)

ViT softmax doygunluğu ($\text{conf}=1.0$) $\rightarrow$ vanilla GradCAM'in gradient'i tam **sıfır** olur; heatmap üretilemez.

EigenCAM gradient gerektirmez — son block aktivasyonlarının **SVD**'sini alır. Sınıf-özel değil, ama her görselde **tutarlı** çalışır.

Önemli not: ****MLP için heatmap üretilemez**** — tam bağlı katmanların uzamsal feature map'i yoktur.

Pratik anekdot: Demoda Roblox görselinde ViT yanlış cevap verdi; EigenCAM modelin avatar yerine ****gökyüzüne baktığını**** gösterdi — hata sebebi anında anlaşıldı.

Canlı Demo — Lokal Web Uygulaması

FastAPI + React · 5 model · belirsizlik göstergesi

Lokal web uygulaması üç adımdan oluşur: **görsel yükleme** (drag-drop veya hazır örnekler), **model seçimi** (tek model ya da "tümünü karşılaştır") ve **sonuç görüntüleme** (Top-3 tahminler + Grad-CAM/EigenCAM heatmap + belirsizlik rozeti).

Belirsizlik Göstergesi (entropy + margin)

Her tahmin için Shannon **entropy** (sınıf olasılıkları dağılımı) ve top-1 ile top-2 arasındaki **margin** hesaplanır. Bu iki sinyal **3 seviyeli rozet** üretir:

-  **Kesin** — yüksek max prob (≥ 0.85), geniş margin (≥ 0.50), düşük entropy.
-  **Şüpheli** — orta seviye güven; top-1 ve top-2 yarışıyor olabilir.
-  **Belirsiz** — düşük max prob (< 0.50) veya yüksek entropy.

OOD sinyali: comparison modunda 3+ model "low" işaretlerse, görsel muhtemelen 10 sınıf dışı (out-of-distribution).

► Şimdi tarayıcıda ****http://localhost:5173**** açıyorum: hazır örneklerden bir konsensüs vakası (Minecraft) ve 3 modelin çeliştiği bir vaka (Fortnite) göstereceğim, ardından listede olmayan bir oyun yükleyip OOD davranışını deneyeceğim.

Sonuç Değerlendirmesi · Sınırlamalar · Erişim

Genel değerlendirme · gelecek çalışma · projeye nereden ulaşılır

Sonuç Değerlendirmesi

Mimari fark çoğu zaman maliyet farkıdır. Bu görevde 0,42M parametrelili CNN Scratch ile 86M parametrelili ViT arasında macro-F1 farkı yalnızca 0,018 — **doğruluk değil, verimlilik kararı** önemlidir.

Transfer learning'in en büyük katkısı erken epoch'larda görülür; sıfırdan eğitilen CNN ise yeterli veriyle yine yüksek doğruluğa ulaşır.

Confidence $\neq$ Correctness — model %87 emin olabilir ve yine de yanılabilir. Belirsizlik göstergesi bu durumu kullanıcıya anlık olarak gösterir.

Sınırlamalar & Gelecek Çalışma

Closed-set softmax sınır dışı sınıf için zorunlu tahmin verir; gerçek OOD detection (Mahalanobis, energy-based) eklenmeli.

10K görsel sınırı; daha fazla sınıf ve sahne çeşitliliği (menü, loading ekranı vb.) eklenmeli.

Confidence calibration (temperature scaling) eksik.

Multi-label genişletme (aynı görselde birden fazla oyun ögesi).

Mobil deploy: EfficientNet → ONNX → mobil cihaz.

Blog Yazısına Erişim



<https://github.com/MALiTopkara/YZM304-Derin-Ogrenme/tree/main/proje4>

Ana Referanslar

He et al. 2015 (ResNet) · Tan & Le 2019 (EfficientNet) · Dosovitskiy et al. 2020 (ViT) · Selvaraju et al. 2017 (Grad-CAM) · Bany Muhammad & Yeasin 2020 (EigenCAM) · timm (Wightman, HuggingFace)